

Guia de Estudos

para o Trabalho de Conclusão de Curso

*"Previsão diária de pedidos em e-commerce
com regressão binomial negativa"*

Aluno: Maycon Henrique Aranha da Silva

Orientador: Gustavo Dantas Lobo

MBA Data Science e Analytics - USP/Esalq (PECEGE)

2o Semestre 2025

1. Visao Geral do Projeto

Este guia organiza os topicos e referencias que voce precisa estudar para desenvolver o TCC sobre previsao de demanda em e-commerce usando Regressao Binomial Negativa. O roteiro esta alinhado com a metodologia proposta no Projeto de Pesquisa e com o cronograma de atividades.

Resumo da pesquisa

- Variavel resposta: numero diario de pedidos (variavel de contagem)
- Modelo principal: Regressao Binomial Negativa com regressoras de calendario e lags
- Baseline: mediana sazonal semanal (ultimas 4 semanas)
- Validacao: backtesting rolling one-step ahead com janela expansivel (60 dias)
- Metricas: wMAPE e sMAPE
- Dados: Olist (Kaggle) - olist_orders_dataset.csv
- Linguagem: Python

Mapa de competencias necessarias

Para executar este projeto com solidez, voce precisa dominar 4 areas de conhecimento:

- (A) Modelos de regressao para dados de contagem (Poisson e Binomial Negativa)
- (B) Deteccao e tratamento de sobredispersao
- (C) Validacao temporal e metricas de previsao
- (D) Engenharia de features temporais (calendario, lags, feriados)

2. Favero e Belfiore (2017) - Manual de Analise de Dados

REFERENCIA PRINCIPAL para a fundamentacao teorica do modelo. O Capitulo 14 e inteiramente dedicado a modelos de contagem e cobre Poisson e Binomial Negativo com resolucao algebrica e em software.

Capitulo 14 - Modelos de Regressao para Dados de Contagem (pp. 695-780)

Este e o capitulo mais importante para o seu TCC. Estude-o integralmente.

pp. 695-696 - 14.1 Introducao

Contextualizacao de quando usar modelos de contagem. Entenda por que regressao linear nao e apropriada para variaveis de contagem (numeros inteiros nao negativos).

pp. 697-709 - 14.2 Modelo de Regressao Poisson

Fundamento do modelo de Poisson: distribuicao, funcao de ligacao logaritmica, estimacao por maxima verossimilhanca (MV), significancia estatistica (teste de Wald, razao de verossimilhanca), intervalos de confianca. ESSENCIAL entender antes de avançar para a Binomial Negativa.

pp. 710-711 - 14.2.4 Teste para verificacao de superdispersao

CRITICO para o TCC. Explica como detectar quando a variancia excede a media (superdispersao), invalidando o pressuposto de equidispersao do Poisson. Este teste justifica a escolha da Binomial Negativa no seu projeto.

pp. 712-723 - 14.3 Modelo de Regressao Binomial Negativo

NUCLEO DO SEU TCC. Cobre: distribuicao binomial negativa, parametro de dispersao (ϕ), estimacao por MV (14.3.1, pp. 715-719), significancia (14.3.2, pp. 720-722), intervalos de confianca (14.3.3, pp. 723). Domine a interpretacao dos coeficientes.

pp. 724-745 - 14.4 Estimacao no software Stata

Embora voce use Python, a logica de estimacao e identica. Leia para entender os outputs tipicos: log-likelihood, AIC, BIC, teste de Wald, e a comparacao Poisson vs BN.

pp. 771-780 - Apendice - Modelos inflacionados de zeros

Leitura complementar. Se a sua serie tiver muitos dias com zero pedidos, pode ser necessario considerar um modelo ZIP ou ZINB. Tenha isso como contingencia.

Capitulos complementares do Favero

- Cap. 5 - Distribuicoes de probabilidade (pp. 137-166): revisao de Poisson, Gama e distribuicoes discretas
- Cap. 7 - Testes de hipoteses (pp. 191-240): fundamentos do teste de razao de verossimilhanca
- Cap. 12 - Regressao simples e multipla (pp. 511-600): variaveis dummy (12.2.6, p. 541)

3. Cameron e Trivedi (2013) - Regression Analysis of Count Data

Referencia fundamental e avancada sobre modelos de contagem. E a obra que fundamenta o teste de razao de verossimilhanca (LR test) para comparar Poisson vs Binomial Negativa.

Capitulos prioritarios

pp. Cap. 1-2 - Introduction e Count Data: Basic Setup

Visao geral de dados de contagem, propriedades da distribuicao de Poisson, a distribuicao Binomial Negativa como alternativa. Motivacao para modelos de contagem.

pp. Cap. 3 - Basic Count Regression (Poisson)

Modelo de Poisson como baseline. Estimacao por MV. Interpretacao de coeficientes como taxas de incidencia (IRR). Diagnosticos de ajuste.

pp. Cap. 4 - Generalized Count Regression

ESSENCIAL. Extensoes do Poisson para lidar com sobredispersao: Binomial Negativa (NB1 e NB2), modelos quasi-Poisson. Entenda a diferenca entre NB1 (variância linear) e NB2 (variância quadrática) - o NB2 é o mais comum e provavelmente o que voce usara no Python (statsmodels).

pp. Cap. 5, pp. 139-188 - Model Evaluation and Testing

CRITICO. Testes de especificacao: teste de razao de verossimilhanca (LR test) para comparar Poisson vs NB. O LR test tem distribuicao nao padrao (mistura de massa pontual em zero e meia chi-quadrado). Cameron e Trivedi sao os autores que formalizaram os testes de sobredispersao mais utilizados.

4. Hilbe (2011) - Negative Binomial Regression

A monografia definitiva sobre Regressao Binomial Negativa. Complementa Cameron e Trivedi com foco exclusivo na BN. Use como referencia de consulta para questoes especificas.

Capitulos prioritarios

pp. Cap. 1 - Introduction to Count Regression

Historico da distribuicao de Poisson e da Binomial Negativa. Definicoes formais.

pp. Cap. 4-5 - Negative Binomial Regression (NB2 e NB1)

Detalhamento dos dois tipos principais de BN. O NB2 (Cap. 4) e o padrao na maioria dos softwares. Estimacao, interpretacao, diagnosticos. Leia especialmente sobre o parametro de heterogeneidade (alpha) e sua interpretacao.

pp. Cap. 7 - Negative Binomial Regression: Modeling

Estrategias praticas de modelagem: selecao de variaveis, diagnosticos de ajuste, residuos, influencia. Util para a fase de estimacao do seu modelo.

pp. Cap. 10-11 - Problems with Count Models / Generalized Models

Problemas comuns: excesso de zeros, subdispersao, truncamento. Importante para saber quando a BN padrao pode nao ser suficiente.

5. Favero et al. (2024) - Algoritmo para Sobredispersao

Artigo recente (open access: mdpi.com/2073-431X/13/4/88) que implementa em Python um algoritmo para detectar sobredispersao e inflacao de zeros em modelos de contagem. Diretamente aplicavel ao seu projeto.

O que estudar neste artigo

- Secao 2: Overview of Count Data - revisao concisa de Poisson, BN e modelos inflacionados de zeros
- Secao 3: Likelihood Ratio Test - implementacao do teste LR para sobredispersao
- Secao 4: Vuong Test - teste de selecao entre modelos aninhados e nao aninhados
- Secao 5: Python Algorithm - codigo que voce pode adaptar/referenciar na sua implementacao

DICA PRATICA: O artigo disponibiliza codigo Python que pode servir como referencia para implementar o teste de sobredispersao no seu notebook. Use statsmodels para estimar os modelos e aplique o LR test conforme descrito no artigo.

6. Hyndman e Athanasopoulos (2021) - Forecasting: Principles and Practice

Livro-texto de previsao, disponivel gratuitamente em otexts.com/fpp3. Cobre os fundamentos de avaliacao de previsoes que voce precisa para a validacao do modelo.

Capitulos prioritarios

pp. Cap. 1 - Getting Started

Introducao a previsao. Tipos de dados temporais. O pipeline de um projeto de forecasting.

pp. Cap. 2 - Time Series Graphics

Padroes temporais: tendencia, sazonalidade, ciclos. Use para a analise exploratoria da sua serie de pedidos (identificar sazonalidade semanal, feriados, etc.).

pp. Cap. 3 - Time Series Decomposition

Decomposicao de series. Util para entender os componentes da sua serie de pedidos.

pp. Cap. 5 - The Forecasters Toolbox

ESSENCIAL. Metricas de acuracia (MAE, MAPE, SMAPE) e estrategias de avaliacao. Aqui voce encontra a fundamentacao para wMAPE e SMAPE usados no seu projeto. Secao 5.8 sobre avaliacao com conjuntos de teste temporais (time series cross-validation) fundamenta o seu backtesting rolling one-step ahead.

pp. Cap. 7 - Time Series Regression Models

Modelos de regressao com componentes temporais. Variaveis dummy para sazonalidade, feriados, e efeitos de calendario. Diretamente relevante para as suas regressoras.

Recurso adicional

O livro tem versao interativa com codigo em R. Embora voce use Python, os conceitos e formulas sao identicos. Para implementacao Python, consulte a biblioteca `sktime` ou implemente as metricas manualmente (recomendado para demonstrar dominio no TCC).

7. Fildes et al. (2022) e Makridakis et al. (2022)

Fildes, Ma e Kolassa (2022) - Retail Forecasting: Research and Practice

Artigo de revisao sobre o estado da arte em previsao para varejo. International Journal of Forecasting, 38, 1283-1318.

- Secao 2: panorama dos metodos de previsao usados em varejo
- Secao 3: desafios especificos (dados esparsos, promocoos, novos produtos)
- Secao 5: lacunas entre pesquisa academica e pratica - bom para contextualizar na Introducao

Este artigo justifica POR QUE previsao de demanda em e-commerce e relevante e quais desafios praticos existem. Use-o para fortalecer a Introducao do TCC.

Makridakis, Spiliotis e Assimakopoulos (2022) - M5 Competition

Resultados da competicao M5 (Kaggle) com dados reais do Walmart. International Journal of Forecasting, 38(4), 1346-1364.

- Usou 42.840 series temporais reais de vendas do Walmart
- Top metodos (LightGBM, XGBoost) superaram benchmarks estatisticos em ~22%
- Apenas 7,5% dos participantes superaram o baseline de suavizacao exponencial
- Conclusao: metodos hibridos (ML + features de calendario) tendem a superar baselines simples

Este artigo reforca a motivacao do seu projeto: modelos que incorporam features de calendario e padroes historicos podem superar baselines simples - exatamente a hipotese que voce testa.

8. Conceitos-Chave para Dominar

Abaixo estao os conceitos fundamentais que voce precisa dominar. Para cada um, indico a referencia primaria.

Distribuicao de Poisson Distribuicao discreta para contagem de eventos. Pressuposto: media = variancia (equidispersao). $E(Y) = Var(Y) = \lambda$. Quando este pressuposto falha, temos sobredispersao. (Favero Cap. 14.2; Cameron Cap. 3)
Sobredispersao (Overdispersion) Quando $Var(Y) > E(Y)$. Causa: heterogeneidade nao observada, excesso de zeros, ou correlacao entre eventos. Consequencia: erros-padrao subestimados no Poisson, levando a significancias espurias. Deteccao: teste LR ou teste de Cameron-Trivedi. (Favero 14.2.4; Cameron Cap. 5; Favero et al. 2024)
Regressao Binomial Negativa (NB2) Extensao do Poisson com parametro de dispersao $\alpha > 0$. $Var(Y) = \mu + \alpha * \mu^2$. Quando $\alpha \rightarrow 0$, converge para Poisson. Estimacao por maxima verossimilhanca. O teste $H_0: \alpha=0$ via LR test decide entre Poisson e BN. (Favero Cap. 14.3; Hilbe Cap. 4; Cameron Cap. 4)
Teste de Razao de Verossimilhanca (LR Test) Compara o ajuste de dois modelos aninhados: $LR = 2*(LL_{completo} - LL_{restrito})$. No caso Poisson vs BN: $H_0: \alpha=0$ (Poisson suficiente). Distribuicao sob H_0: mistura $0.5*\chi^2(0) + 0.5*\chi^2(1)$. $p\text{-valor} = 0.5 * P(\chi^2(1) > LR)$. (Cameron Cap. 5; Favero et al. 2024)
Variaveis Dummy de Calendario Indicadores binarios para capturar padroes sazonais: dia da semana (6 dummies, domingo como referencia), feriados nacionais, efeito payday (dias 5 e 20 + 2 dias uteis). Fundamentacao: features de calendario sao standard em previsao de varejo. (Hyndman Cap. 7; Fildes et al. 2022)
Lags Historicos como Regressoras Valores passados da variavel resposta: lag1 (ontem), lag7 (mesmo dia semana passada), lag14 (mesmo dia ha 2 semanas). Capturam autocorrelacao serial e padroes recorrentes. Cuidado: lags introduzem dependencia temporal na estimacao. (Hyndman Cap. 7)

8. Conceitos-Chave (continuacao)

Backtesting Rolling One-Step Ahead

Estrategia de validacao temporal: a cada dia t no periodo de teste (60 dias), reestima o modelo com dados $[1, t-1]$ e preve t . Janela expansivel = o conjunto de treino cresce a cada iteracao. Evita data leakage temporal. (Hyndman Cap. 5, Secao 5.8 - Time Series Cross-Validation)

wMAPE (weighted Mean Absolute Percentage Error)

$wMAPE = \frac{\sum(|y_t - \hat{y}_t|)}{\sum(y_t)}$. Pondera pelo volume real, evitando distorcoes de dias com poucos pedidos. Mais robusto que MAPE para series com valores proximos de zero. (Hyndman Cap. 5)

sMAPE (symmetric Mean Absolute Percentage Error)

$sMAPE = (1/n) * \sum(2 * |y_t - \hat{y}_t| / (|y_t| + |\hat{y}_t|))$. Simetrico entre sobre e subestimacao. Varia de 0% (perfeito) a 200% (pior caso). Amplamente usado em competicoes de previsao (M3, M4, M5). (Hyndman Cap. 5; Makridakis et al. 2022)

Baseline Sazonal Semanal

Modelo de referencia simples: previsao = mediana dos pedidos no mesmo dia da semana nas 4 semanas anteriores. Captura sazonalidade semanal sem modelagem parametrica. Todo modelo proposto deve ser comparado a um baseline interpretavel. (Hyndman Cap. 5)

9. Roteiro de Estudo Sugerido

Organize seus estudos nas seguintes fases, alinhadas ao cronograma do Projeto de Pesquisa:

Fase 1 - Fundamentacao Teorica (Abril-Maio)

- Estudar Favero Cap. 14 integralmente (pp. 695-780) - 2 a 3 semanas
- Ler Cameron & Trivedi Cap. 3-5 (foco nos Cap. 4-5) - 1 a 2 semanas
- Ler Fildes et al. (2022) e Makridakis et al. (2022) para contextualizar - 2 dias
- Revisar Hyndman Cap. 1-3 e Cap. 7 sobre features temporais - 1 semana

Fase 2 - Implementacao (Maio-Julho)

- Estudar Favero et al. (2024) - algoritmo de sobredispersao em Python - 2 dias
- Implementar pipeline de dados: leitura Olist, filtros, serie diaria
- Implementar teste de sobredispersao (LR test) com statsmodels
- Estimar modelo BN com statsmodels (NegativeBinomial ou GLM)
- Implementar baseline sazonal e backtesting rolling
- Consultar Hilbe Cap. 4-5 e 7 para duvidas sobre modelagem

Fase 3 - Avaliacao e Redacao (Julho-Setembro)

- Calcular wMAPE e sMAPE - consultar Hyndman Cap. 5 para fundamentacao
- Comparar modelo BN vs baseline e interpretar resultados
- Redigir TCC seguindo template e normas USP/Esalq
- Revisitar Cameron & Trivedi e Hilbe para fundamentar a discussao

Fase 4 - Revisao e Defesa (Setembro-Outubro)

- Revisar formatacao conforme Manual de Instrucoes e Normas
- Preparar slides (20 min) focando em: problema, metodo, resultados, conclusao
- Praticar defesa e antecipacao de perguntas da banca

10. Ferramentas Python Recomendadas

Bibliotecas que voce usara no projeto:

Manipulacao de dados

- pandas - leitura CSV, agregacao temporal, criacao de features
- numpy - operacoes numericas

Modelagem estatistica

- statsmodels.discrete.count_model.NegativeBinomial - modelo BN
- statsmodels.genmod.generalized_linear_model.GLM (family=NegativeBinomial) - alternativa via GLM
- statsmodels.discrete.count_model.Poisson - modelo Poisson (para comparacao)
- scipy.stats.chi2 - para calcular p-valor do LR test

Features de calendario

- holidays (pip install holidays) - feriados nacionais brasileiros
- pandas.Categorical / pd.get_dummies - dummies de dia da semana

Visualizacao

- matplotlib / seaborn - graficos da serie, residuos, comparacoes

Validacao

- Implementacao manual do backtesting rolling (loop com reestimacao)
- sklearn.metrics ou implementacao manual de wMAPE e sMAPE

Este guia foi elaborado com base nos manuais do curso e nas referencias do Projeto de Pesquisa. Foque nos capitulos indicados como prioritarios e avance para os complementares conforme necessidade.